

ORBITAI AGRORISK

Guilherme Silva Cavalcanti – 98928

Paulo Henrique da Silva Lima – 552444

Wesley Assis Oliveira – 552516

4SIR

Global Solution — Machine Learning + Economia Espacial
Relatório Técnico de Validação e Arquitetura

1. Resumo

O crescimento exponencial da economia espacial nas últimas décadas expandiu as fronteiras tecnológicas, permitindo que a infraestrutura orbital e o sensoriamento remoto por satélites fossem aplicados diretamente na resolução de desafios críticos na superfície terrestre. O agronegócio brasileiro, um dos pilares mais representativos do Produto Interno Bruto (PIB) nacional, encontra-se altamente vulnerável a flutuações e eventos climáticos extremos. Anomalias térmicas, estiagens prolongadas e distribuições irregulares de precipitação resultam em perdas severas de produtividade e impactos econômicos em cascata.

Nesse contexto, o projeto **OrbitAI AgroRisk** surge como uma solução disruptiva baseada em Inteligência Artificial e Machine Learning. O sistema processa e analisa dados macroclimáticos integrados a índices biofísicos de vegetação obtidos via satélite, gerando modelos preditivos robustos capazes de classificar o nível de risco de talhões agrícolas antes que os danos físicos e prejuízos financeiros se consolidem em campo. A solução atua como um motor de decisão inteligente para produtores, cooperativas e seguradoras.

2. O Problema

A agricultura contemporânea enfrenta uma volatilidade climática sem precedentes devido às mudanças climáticas globais. A degradação estrutural do solo e a escassez de recursos hídricos afetam diretamente a segurança alimentar e a previsibilidade financeira no campo. A dor central identificada reside na reatividade do setor: a grande maioria das tomadas de decisão e ações corretivas ocorre apenas após a consolidação visual do estresse hídrico ou térmico na cultura, momento em que a perda de rendimento já se tornou irreversível.

Apesar da ampla disponibilidade de dados de telemetria e constelações de satélites públicos e privados monitorando a Terra continuamente, há um gap técnico na ingestão, limpeza e modelagem inteligente desses dados brutos para gerar diagnósticos preditivos e acionáveis na ponta final da cadeia.

3. Objetivo e Hipótese

Objetivo Geral

Desenvolver, avaliar e documentar um pipeline completo de Ciência de Dados e Machine Learning capaz de inferir os níveis de risco agroclimático de talhões agrícolas com base em geolocalização, dados meteorológicos de superfície e variáveis de reflectância espectral orbital.

Hipótese de Trabalho

A combinação sinérgica de indicadores contínuos de umidade do solo com o índice NDVI (Índice de Vegetação por Diferença Normalizada) obtido por sensores espectrais orbitais fornece assinaturas biofísicas suficientes para que algoritmos de aprendizado supervisionado

baseados em árvores consigam mapear e segmentar com precisão o risco de estresse ambiental crítico antes da perda total da lavoura.

4. Arquitetura da Solução e Metodologia

O pipeline de engenharia e modelagem foi concebido seguindo as melhores práticas do ecossistema de dados em Python, dividido em quatro pilares fundamentais:

- **1. Engenharia de Atributos (Data Simulation):** Simula um ecossistema real composto por 1.000 talhões agrícolas e 6 variáveis estruturadas: Latitude, Longitude, Temperatura Média (°C), Precipitação Anual (mm), Umidade do Solo (%) e o Índice de Vegetação por Diferença Normalizada (NDVI).
- **2. Saneamento de Dados (Data Cleaning):** Para representar com precisão os desafios operacionais do sensoriamento remoto (como obstruções por cobertura de nuvens), injetou-se programaticamente 3% de ruído/valores ausentes (NaN) na coluna NDVI. O pipeline executa o tratamento estatístico automatizado via imputação por média.
- **3. Modelagem Supervisionada:** Os dados saneados alimentam o algoritmo supervisionado Random Forest Classifier. O dataset é particionado de forma estratificada na proporção 80/20 para treinamento e validação, garantindo a distribuição homogênea das classes em ambos os conjuntos.
- **4. Simulador de Inferência Real-Time:** Desenvolvimento de uma camada funcional que atua como microsserviço de inferência rápida. Ao receber parâmetros instantâneos de telemetria de qualquer propriedade, o backend responde imediatamente com a classe predita e a respectiva probabilidade de confiança.

5. Estrutura do Repositório

Para atender aos critérios de reprodutibilidade científica e organização corporativa, o script principal foi projetado para gerenciar o sistema operacional e estruturar a arquitetura do projeto de forma 100% automatizada. Caso o usuário execute o código em um diretório virgem, as subpastas serão geradas imediatamente sem necessidade de intervenção manual:

```
📁 orbitai-agrorisk
├── 📁 data
│   └── base_orbitai_limpa.csv      # Dataset gerado, limpo e estruturado pelo
pipeline
├── 📁 img
│   ├── matriz_confusao.png        # Matriz de acertos e validação cruzada
│   └── importancia_variaveis.png  # Gráfico estatístico de relevância dos
atributos orbitais
└── orbitai_risk.py                 # Script unificado (Engine e Core da IA)
```

6. Análise Técnica e Resultados

O classificador Random Forest foi validado utilizando a matriz de confusão e métricas clássicas de desempenho (Precisão, Recall e F1-Score). O modelo consolidou uma Acurácia Geral de 93.00% nos dados de teste, um resultado altamente robusto para dados ambientais não-lineares.

Métricas de Desempenho do Modelo

Classe de Risco	Precisão (Precision)	Cobertura (Recall)	F1-Score	Suporte (Amostras)
Baixo Risco (●)	0.96	0.97	0.97	106
Médio Risco (○)	0.88	0.95	0.91	75
Alto Risco (●)	1.00	0.63	0.77	19

Insights Estratégicos dos Resultados

- Precisão Absoluta em Alto Risco:** A métrica de precisão para a classe de maior severidade atingiu 1.00 (100%). Em termos práticos e comerciais, isso significa falso alarme zero para alertas de alta criticidade. Seguradoras agrícolas e cooperativas podem confiar plenamente nas notificações do sistema para acionar equipes ou travar apólices sem o risco de deslocar recursos por engano.
- Segurança Operacional e Mitigação de Riscos:** A avaliação detalhada da matriz de confusão indica que o algoritmo não registrou nenhuma ocorrência de falsos negativos críticos (classificar uma área que era Alto Risco real como Baixo Risco). Erros desse tipo seriam fatais, pois fariam com que uma quebra severa passasse despercebida.
- Dominância das Variáveis Orbitais:** A análise de feature importance do Random Forest comprovou estatisticamente a hipótese inicial: o índice espectral NDVI e a taxa de umidade do solo combinados detêm mais de 65% do peso de decisão do modelo, demonstrando que os dados derivados da economia espacial são determinantes para a inteligência agrícola.

7. Conclusão

O OrbitAI AgroRisk valida empiricamente que o casamento entre a Inteligência Artificial estruturada e os dados de sensoriamento remoto da economia espacial oferece uma resposta escalável, sustentável e de alta precisão para a segurança preditiva no campo. Ao automatizar a criação de diretórios, o tratamento de missing data e disponibilizar um simulador em tempo real com 93.00% de acurácia, o projeto consolida-se como um modelo de arquitetura de software e Ciência de Dados pronto para o mercado.